

## A11 - Dyfuzja innowacji i popytu na rynku

---

Wojciech Bartoszek

Łukasz Checiak

## **Zadanie 1 - Wprowadzenie, SOTA i sformułowanie modelu**

---

- **Dyfuzja innowacji** – proces upowszechniania się nowych produktów lub technologii w społeczeństwie, przechodzący kolejne fazy adopcji kolejnych grup odbiorców [?].
- Proces adopcji przebiega początkowo wolno, następnie nabiera tempa, często zgodnie z charakterystyczną krzywą S (funkcja logistyczna) [?].
- Wzrost popytu na innowację wspierają zarówno innowatorzy (early adopters), jak i mechanizm naśladownictwa („word-of-mouth”).
- Modele matematyczne umożliwiają kwantyfikację dynamiki popytu i adopcji (prognozowanie rozmiaru rynku) [?].

- **Model Bassa** (1969) – równanie różniczkowe opisujące tempo adopcji nowego produktu. Zakłada dwie kategorie nabywców: *innowatorów* (efekt zewnętrzny) i *naśladowców* (efekt imitacji). Równanie:  
$$\frac{dF}{dt} = p(1 - F) + qF(1 - F),$$
 gdzie  $F(t)$  to skumulowany udział adopcji,  $p$  – współczynnik innowacji,  $q$  – współczynnik imitacji [?]. Rozwiązanie daje S-kształtną krzywą adopcji: początkowo szybki wzrost, potem nasycenie.
- **Równanie Fishera–Kolmogorowa–Petrowskiego–Piskunowa (F-KPP)** – reakcyjno-dyfuzyjne równanie PDE:  $u_t = D\Delta u + r u(1 - u)$  [?].  
Proponowane w genetyce populacji (Fisher 1937) do opisanie fali rozprzestrzeniania korzystnego genu. W ekonomii modeluje propagację innowacji jako falę nasycenia (przejście od stanu bez adopcji do pełnej adopcji).
- **Przebieg krzywej adopcji** – obydwa powyższe modele generują krzywą typu logistycznego (S-kształtną): szybka faza początkowa (wzrost adopcji) i faza wygaszania przy nasyceniu rynku [?, ?].

## Uogólnienie do modeli przestrzenno-czasowych (PDE)

- Dodanie wymiaru przestrzennego do modelu Bassa prowadzi do *równania cząstkowego różniczkowego*:

$$\frac{\partial F(x, t)}{\partial t} = D\Delta F + p(1 - F) + qF(1 - F),$$

gdzie  $D$  to współczynnik dyfuzji (intensywność rozprzestrzeniania informacji w przestrzeni) [?].

- Takie modele reakcji–dyfuzji uwzględniają mechanizmy lokalnej interakcji (zależność od odległości przestrzennej) oraz pierwiastek losowy/adopcyjny w zachowaniach konsumentów.
- Rozwiązania przyjmują formę propagujących się fal innowacji (autowal). Ich prędkość opisuje tempo rozwoju popytu w przestrzeni – np. Dubinina (2023) analitycznie wyprowadza falę podróżującą, określając czas osiągnięcia danego poziomu technologii [?].
- W praktyce modele PDE pozwalają analizować klastrowe rozprzestrzenianie się innowacji (np. koncentrujące się „fale adopcji” wokół centrów innowacyjności) oraz prognozować przestrzenne rozkłady popytu.

- Rozważmy zmienną  $u(x, t) \in [0, 1]$  – skumulowany udział rynku opanowany przez innowację w punkcie  $x$  i czasie  $t$ . Proponowany model:

$$\frac{\partial u}{\partial t} = D \Delta u + (p + q u) (1 - u).$$

- Interpretacja parametrów:  $p$  – stopa innowacji (zewnętrzna, np. reklama),  $q$  – współczynnik imitacji (wewnętrzny, efekt „liczenia się z innymi”),  $D$  – współczynnik dyfuzji (szybkość propagacji informacji w przestrzeni).
- Warunki początkowe i brzegowe: np.  $u(x, 0) = u_0(x)$  z niewielką liczbą pionierów w centrum, warunki Neumanna ( $\nabla u \cdot n = 0$ ) na granicach.
- Model przewiduje przyspieszony wzrost adopcji w początkowej fazie i asymptotyczne nasycenie rynku ( $u \rightarrow 1$ ). Rozwiązania (np. numeryczne lub w przybliżeniu falowe) pozwalają wyznaczyć czas rozprzestrzeniania innowacji i tempo wzrostu popytu [?].

- Modele przestrzenno-czasowe umożliwiają uwzględnienie efektów geograficznych: jak bliskość i sieci społeczne przyspieszają dyfuzję innowacji [?].
- Zastosowania: prognozowanie rozkładu adopcji w regionach, identyfikacja klastrów innowacji, planowanie strategii marketingowych z uwzględnieniem lokalizacji (marketing geograficzny).
- Kalibracja na danych empirycznych (np. historia adopcji technologii mobilnej) umożliwia przewidywanie tempa wzrostu popytu i oceny opóźnień geograficznych (patrz Dubinina 2023) [?].
- Dalszy rozwój modeli może uwzględniać heterogeniczność populacji, zależność od cen czy czynniki sieciowe, co można wprowadzić jako dodatkowe składniki PDE (np. sprzężenia zwrotne, nieliniowe czynniki) [?].

## **Zadanie 2 - Porównanie solverów dla modelu przestrzenno-czasowego**

---



- Rozważamy model reakcyjno-dyfuzyjny dla udziału adopcji  $u(x, t) \in [0, 1]$ :

$$\frac{\partial u}{\partial t} = D \frac{\partial^2 u}{\partial x^2} + (p + q u)(1 - u).$$

- Parametry:  $D$  (dyfuzja),  $p$  (innowacja),  $q$  (imitacja). Warunki Neumanna na brzegach oraz lokalne warunki początkowe (pionierzy w centrum).
- Celem: porównać wydajność i stabilność rozwiązań dla różnych solverów oraz zidentyfikować bezpieczne przedziały parametrów.


- explicit: jawny Euler w czasie + centralna druga różnica w przestrzeni (najtańszy krok, ograniczony warunkiem CFL).
- semi-implicit: dyfuzja implicit (rozwiązanie układu liniowego), reakcja jawnie.
- crank-nicolson (CN): CN dla dyfuzji (2. rząd dokładności), reakcja jawnie; większy koszt na krok.

- Siatki w przestrzeni:  $n_x \in \{50, 100, 200\}$ .
- Kroki czasowe testowane:  $\Delta t \in \{5 \cdot 10^{-5}, 10^{-4}\}$ , całkowity czas symulacji:  $T = 0.05$  (szybkie testy).
- Zestaw parametrów (D,p,q): (0.01,0.01,1.0), (0.1,0.001,5.0), (1.0,0.1,10.0).
- Mierzone metryki: czas wykonania (s), wykresy profilu  $u(x)$ , kontrola czy  $u \in [0, 1]$  i czy występują NaN/Inf.


Wyniki z przebiegu eksperymentu (nagłówek: średni czas wyk. dla wszystkich kombinacji testowych):

- explicit — średni czas:  $\approx 0.0048$  s (min  $\approx 0.0029$  s, max  $\approx 0.0068$  s)
- semi-implicit — średni czas:  $\approx 0.0329$  s (min  $\approx 0.0164$  s, max  $\approx 0.0568$  s)
- crank-nicolson — średni czas:  $\approx 0.0350$  s (min  $\approx 0.0178$  s, max  $\approx 0.0596$  s)


# Przykładowe profile rozwiązania



(a) explicit,  $nx=100$



(b) semi-implicit,  $nx=100$



(c) Crank-Nicolson,  $nx=100$

- (1) Czas obliczeń: dla krótkich testów jawny solver był najszybszy ze względu na niski koszt pojedynczego kroku; schematy rozwiązujące układy liniowe były wolniejsze.
- (2) Stabilność: jawny (explicit) solver wymaga mniejszego kroku czasowego  $\Delta t$  przy wzroście  $D$  ( $\text{CFL} \sim dx^2/D$ ); schematy semi-implicit i CN są bardziej odporne, ale droższe.
- (3) Parametry  $p, q$ : większe  $q$  przyspieszają nasycenie i mogą prowadzić do szybkich wzrostów lokalnych; zalecamy testy kalibracyjne na danych empirycznych.
- (4) Zakresy parametryczne (przykładowo): dla stabilnych symulacji przy  $n_x = 100$  i  $dt = 10^{-4}$  przykładowe granice to:  $D \lesssim 0.1$  (dla explicit),  $p \in [10^{-4}, 0.1]$ ,  $q \in [0.1, 10]$  — jednak ostateczne granice wymagają szczegółowego testu stabilności i dokładności.

## **Zadanie 3 — Model surogatowy ODE dla dyfuzji innowacji**

---

- **Cel:** Uproszczenie modelu PDE do modelu ODE poprzez eliminację zmiennej przestrzennej. Pozwala to na znacznie szybsze symulacje.
- **Metoda:** Uśrednienie równania PDE po całej dziedzinie przestrzennej  $x \in [0, 1]$ .

$$\frac{d}{dt} \int_0^1 u(x, t) dx = \int_0^1 Du_{xx} dx + \int_0^1 (p + qu)(1 - u) dx$$


- Przy warunkach brzegowych Neumanna, człon dyfuzyjny się zeruje:  
 $\int_0^1 Du_{xx} dx = D[u_x]_0^1 = 0$ .
- Definiując  $U(t) = \mathbb{E}[u(x, t)] = \int_0^1 u(x, t) dx$  i stosując przybliżenie  $\mathbb{E}[R(u)] \approx R(\mathbb{E}[u])$ , otrzymujemy model surogatowy ODE:

$$\frac{dU}{dt} = (p + qU)(1 - U)$$



- Używamy prostej sieci neuronowej (MLP) do nauczenia się dynamiki średniej wartości  $U(t)$  bezpośrednio z danych.
- **Dane uczące:** Szereg czasowy średniej wartości z symulacji PDE,  $\{(t_i, U_{PDE}(t_i))\}$ .
- **Architektura:** Sieć z jedną warstwą wejściową (czas), dwiema warstwami ukrytymi (z funkcją aktywacji ReLU) i jedną warstwą wyjściową (przewidywana wartość  $U(t)$ ).
- **Cel:** Sprawdzenie, czy model oparty na danych może być dokładniejszy niż uproszczony model analityczny ODE.

# Porównanie wszystkich trzech modeli



**Rysunek 2:** Porównanie średniej z modelu PDE, modelu surogatowego ODE oraz predykcji sieci neuronowej.

- Modele surogatowe (zarówno analityczne ODE, jak i sieci neuronowe) są potężnym narzędziem do przyspieszania symulacji złożonych systemów PDE.
- Model ODE, mimo swojej prostoty, dostarcza dobrego przybliżenia ogólnej dynamiki systemu.
- Sieci neuronowe mogą osiągnąć wyższą dokładność, ale wymagają danych treningowych i nie dostarczają analitycznego wglądu w mechanizmy systemu.
- Wybór odpowiedniego modelu surogatowego zależy od wymagań dotyczących dokładności, dostępności danych i potrzeby interpretowalności wyników.