

A11 - Dyfuzja innowacji i popytu na rynku

Wojciech Bartoszek

Łukasz Checiak

Zadanie 1 - Wprowadzenie, SOTA i sformułowanie modelu

- **Dyfuzja innowacji** – proces upowszechniania się nowych produktów lub technologii w społeczeństwie, przechodzący kolejne fazy adopcji kolejnych grup odbiorców [?].
- Proces adopcji przebiega początkowo wolno, następnie nabiera tempa, często zgodnie z charakterystyczną krzywą S (funkcja logistyczna) [?].
- Wzrost popytu na innowację wspierają zarówno innowatorzy (early adopters), jak i mechanizm naśladownictwa („word-of-mouth”).
- Modele matematyczne umożliwiają kwantyfikację dynamiki popytu i adopcji (prognozowanie rozmiaru rynku) [?].

- **Model Bassa** (1969) – równanie różniczkowe opisujące tempo adopcji nowego produktu. Zakłada dwie kategorie nabywców: *innowatorów* (efekt zewnętrzny) i *naśladowców* (efekt imitacji). Równanie:
$$\frac{dF}{dt} = p(1 - F) + qF(1 - F),$$
 gdzie $F(t)$ to skumulowany udział adopcji, p – współczynnik innowacji, q – współczynnik imitacji [?]. Rozwiązanie daje S-kształtną krzywą adopcji: początkowo szybki wzrost, potem nasycenie.
- **Równanie Fishera–Kolmogorowa–Petrowskiego–Piskunowa (F-KPP)** – reakcyjno-dyfuzyjne równanie PDE: $u_t = D\Delta u + r u(1 - u)$ [?].
Proponowane w genetyce populacji (Fisher 1937) do opisania fali rozprzestrzeniania korzystnego genu. W ekonomii modeluje propagację innowacji jako falę nasycenia (przejście od stanu bez adopcji do pełnej adopcji).
- **Przebieg krzywej adopcji** – obydwa powyższe modele generują krzywą typu logistycznego (S-kształtną): szybka faza początkowa (wzrost adopcji) i faza wygaszania przy nasyceniu rynku [?, ?].

Uogólnienie do modeli przestrzenno-czasowych (PDE)

- Dodanie wymiaru przestrzennego do modelu Bassa prowadzi do *równania cząstkowego różniczkowego*:

$$\frac{\partial F(x, t)}{\partial t} = D\Delta F + p(1 - F) + q F(1 - F),$$

gdzie D to współczynnik dyfuzji (intensywność rozprzestrzeniania informacji w przestrzeni) [?].

- Takie modele reakcji–dyfuzji uwzględniają mechanizmy lokalnej interakcji (zależność od odległości przestrzennej) oraz pierwiastek losowy/adopcyjny w zachowaniach konsumentów.
- Rozwiązania przyjmują formę propagujących się fal innowacji (autowal). Ich prędkość opisuje tempo rozwoju popytu w przestrzeni – np. Dubinina (2023) analitycznie wyprowadza falę podróżującą, określając czas osiągnięcia danego poziomu technologii [?].
- W praktyce modele PDE pozwalają analizować klastrowe rozprzestrzenianie się innowacji (np. koncentrujące się „fale adopcji” wokół centrów innowacyjności) oraz prognozować przestrzenne rozkłady popytu.

- Rozważmy zmienną $u(x, t) \in [0, 1]$ – skumulowany udział rynku opanowany przez innowację w punkcie x i czasie t . Proponowany model:

$$\frac{\partial u}{\partial t} = D \Delta u + (p + q u)(1 - u).$$

- Interpretacja parametrów: p – stopa innowacji (zewnętrzna, np. reklama), q – współczynnik imitacji (wewnętrzny, efekt „liczenia się z innymi”), D – współczynnik dyfuzji (szybkość propagacji informacji w przestrzeni).
- Warunki początkowe i brzegowe: np. $u(x, 0) = u_0(x)$ z niewielką liczbą pionierów w centrum, warunki Neumanna ($\nabla u \cdot n = 0$) na granicach.
- Model przewiduje przyspieszony wzrost adopcji w początkowej fazie i asymptotyczne nasycenie rynku ($u \rightarrow 1$). Rozwiązania (np. numeryczne lub w przybliżeniu falowe) pozwalają wyznaczyć czas rozprzestrzeniania innowacji i tempo wzrostu popytu [?].

- Modele przestrzenno-czasowe umożliwiają uwzględnienie efektów geograficznych: jak bliskość i sieci społeczne przyspieszają dyfuzję innowacji [?].
- Zastosowania: prognozowanie rozkładu adopcji w regionach, identyfikacja klastrów innowacji, planowanie strategii marketingowych z uwzględnieniem lokalizacji (marketing geograficzny).
- Kalibracja na danych empirycznych (np. historia adopcji technologii mobilnej) umożliwia przewidywanie tempa wzrostu popytu i oceny opóźnień geograficznych (patrz Dubinina 2023) [?].
- Dalszy rozwój modeli może uwzględniać heterogeniczność populacji, zależność od cen czy czynniki sieciowe, co można wprowadzić jako dodatkowe składniki PDE (np. sprzężenia zwrotne, nieliniowe czynniki) [?].

Zadanie 2 - Porównanie solverów dla modelu przestrzenno-czasowego

- Rozważamy model reakcyjno-dyfuzyjny dla udziału adopcji $u(x, t) \in [0, 1]$:

$$\frac{\partial u}{\partial t} = D \frac{\partial^2 u}{\partial x^2} + (p + q u)(1 - u).$$

- Parametry: D (dyfuzja), p (innowacja), q (imitacja). Warunki Neumanna na brzegach oraz lokalne warunki początkowe (pionierzy w centrum).
- Celem: porównać wydajność i stabilność rozwiązań dla różnych solverów oraz zidentyfikować bezpieczne przedziały parametrów.


- explicit: jawny Euler w czasie + centralna druga różnica w przestrzeni (najtańszy krok, ograniczony warunkiem CFL).
- semi-implicit: dyfuzja implicit (rozwiązanie układu liniowego), reakcja jawnie.
- crank-nicolson (CN): CN dla dyfuzji (2. rząd dokładności), reakcja jawnie; większy koszt na krok.

- Siatki w przestrzeni: $n_x \in \{50, 100, 200\}$.
- Kroki czasowe testowane: $\Delta t \in \{5 \cdot 10^{-5}, 10^{-4}\}$, całkowity czas symulacji: $T = 0.05$ (szybkie testy).
- Zestaw parametrów (D,p,q): (0.01,0.01,1.0), (0.1,0.001,5.0), (1.0,0.1,10.0).
- Mierzone metryki: czas wykonania (s), wykresy profilu $u(x)$, kontrola czy $u \in [0, 1]$ i czy występują NaN/Inf.


Wyniki z przebiegu eksperymentu (nagłówek: średni czas wyk. dla wszystkich kombinacji testowych):

- explicit — średni czas: ≈ 0.0048 s (min ≈ 0.0029 s, max ≈ 0.0068 s)
- semi-implicit — średni czas: ≈ 0.0329 s (min ≈ 0.0164 s, max ≈ 0.0568 s)
- crank-nicolson — średni czas: ≈ 0.0350 s (min ≈ 0.0178 s, max ≈ 0.0596 s)


Przykładowe profile rozwiązania



(a) explicit, $nx=100$



(b) semi-implicit, $nx=100$



(c) Crank-Nicolson, $nx=100$

- (1) Czas obliczeń: dla krótkich testów jawny solver był najszybszy ze względu na niski koszt pojedynczego kroku; schematy rozwiązujące układy liniowe były wolniejsze.
- (2) Stabilność: jawny (explicit) solver wymaga mniejszego kroku czasowego Δt przy wzroście D ($CFL \sim dx^2/D$); schematy semi-implicit i CN są bardziej odporne, ale droższe.
- (3) Parametry p, q : większe q przyspieszają nasycenie i mogą prowadzić do szybkich wzrostów lokalnych; zalecamy testy kalibracyjne na danych empirycznych.
- (4) Zakresy parametryczne (przykładowo): dla stabilnych symulacji przy $n_x = 100$ i $dt = 10^{-4}$ przykładowe granice to: $D \lesssim 0.1$ (dla explicit), $p \in [10^{-4}, 0.1]$, $q \in [0.1, 10]$ — jednak ostateczne granice wymagają szczegółowego testu stabilności i dokładności.

Zadanie 3 — Model surogatowy ODE dla dyfuzji innowacji

- **Cel:** Uproszczenie modelu PDE do modelu ODE poprzez eliminację zmiennej przestrzennej. Pozwala to na znacznie szybsze symulacje.
- **Metoda:** Uśrednienie równania PDE po całej dziedzinie przestrzennej $x \in [0, 1]$.


$$\frac{d}{dt} \int_0^1 u(x, t) dx = \int_0^1 Du_{xx} dx + \int_0^1 (p + qu)(1 - u) dx$$

- Przy warunkach brzegowych Neumanna, człon dyfuzyjny się zeruje:
 $\int_0^1 Du_{xx} dx = D[u_x]_0^1 = 0$.
- Definiując $U(t) = \mathbb{E}[u(x, t)] = \int_0^1 u(x, t) dx$ i stosując przybliżenie $\mathbb{E}[R(u)] \approx R(\mathbb{E}[u])$, otrzymujemy model surogatowy ODE:

$$\frac{dU}{dt} = (p + qU)(1 - U)$$

- **Cel:** Stworzenie uniwersalnego modelu surogatowego, który generalizuje dynamikę dla różnych parametrów D, p, q .
- **Dane uczące:** Zbiór symulacji PDE dla losowych kombinacji parametrów (uczenie na wielu przebiegach).
- **Architektura:** Sieć MLP z wejściem 4-wymiarowym (t, D, p, q) , dwiema warstwami ukrytymi i wyjściem $U(t)$.
- **Wynik:** Sieć nauczyła się odwzorowywać wpływ parametrów na krzywą adopcji, co pozwala na natychmiastową predykcję dla nowych, nieznanych wcześniej parametrów.

Porównanie wszystkich trzech modeli



Rysunek 2: Porównanie średniej z modelu PDE, modelu surogatowego ODE oraz predykcji sieci neuronowej.

- Parametry testowe: $D = 0.02$, $p = 0.079$, $q = 6.68$.
- Czas inferencji dla modelu ODE: ≈ 1.29 ms.
- Czas inferencji dla modelu NN: ≈ 0.87 ms.


- Modele surogatowe (zarówno analityczne ODE, jak i sieci neuronowe) są potężnym narzędziem do przyspieszania symulacji złożonych systemów PDE.
- Model ODE, mimo swojej prostoty, dostarcza dobrego przybliżenia ogólnej dynamiki systemu.
- Sieć neuronowa wytrenowana na zbiorze symulacji potrafi generalizować i przewidywać dynamikę dla nowych parametrów z bardzo wysoką dokładnością i w czasie poniżej 1 ms.
- Wybór odpowiedniego modelu surogatowego zależy od wymagań dotyczących dokładności, dostępności danych i potrzeby interpretowalności wyników.

Zadanie 4: Analiza Wrażliwości

- **Cel:** Zidentyfikowanie, które parametry wejściowe (D, p, q) mają największy wpływ na wynik modelu (średnia wartość U w czasie $t = 5.0$).
- **Analizowane modele:**
 - Pełny model czasowo-przestrzenny (PDE).
 - Uproszczony model czasowy (surogat ODE).
- **Użyte metody:**
 - **Metoda Morrisa:** Metoda przesiewowa, szybka, do identyfikacji najważniejszych parametrów. Mierzy ogólny wpływ (μ^*) i interakcje/nieliniowość (σ).
 - **Metoda Sobola:** Metoda globalna oparta na wariancji. Dokładniejsza, ale kosztowniejsza. Rozdziela wariancję wyjścia na wpływ poszczególnych parametrów ($S1$) i ich interakcje (ST).

Model ODE


Analiza Morrisa dla Model ODE



Parametry w prawym górnym rogu są najważniejsze i najbardziej nieliniowe.

Model PDE

Analiza Morrisa dla Model PDE




Parametry w prawym górnym rogu są najważniejsze i najbardziej nieliniowe.

- **Wnioski:** W obu modelach parametr **q** (imitacja) wykazuje największy wpływ (najwyższe μ^*) oraz znaczące interakcje (wysokie σ). Parametr **p** ma umiarkowany wpływ, a **D** (w modelu PDE) jest najmniej istotny.


Model ODE

Analiza Sobola dla Model ODE



Model PDE

Analiza Sobola dla Model PDE



- **Potwierdzenie:** Analiza Sobola potwierdza wyniki z metody Morrisa.
- **Wpływ całkowity (ST):** Parametr **q** ma dominujący wpływ.
- **Interakcje:** Duża różnica między **ST** a **S1** dla parametru **q** wskazuje na jego silne interakcje z innymi parametrami.
- **Wpływ D:** Wpływ parametru **D** na średnią wartość $U(t)$ jest marginalny.

Wnioski z Analizy Wrażliwości:

- Parametr imitacji (q) jest kluczowym czynnikiem sterującym dynamiką średniego poziomu adaptacji $U(t)$.
- Parametr innowacji (p) jest drugorzędny, ale wciąż istotny.
- Parametr dyfuzji (D) ma znikomy wpływ na *średnią* wartość w systemie, chociaż jest kluczowy dla dynamiki *przestrzennej*.


Propozycja uproszczenia modelu:

- Model ODE jest już uproszczeniem, które ignoruje D . Analiza potwierdza, że jest to uzasadnione, jeśli interesuje nas tylko średnia wartość $U(t)$.
- W modelu PDE, parametr D można by ustalić na stałą wartość (np. jego średnią z badanego zakresu) bez dużej utraty dokładności dla tej konkretnej miary wyjściowej. To redukuje złożoność problemu o jeden wymiar.

Zadanie 5 — Asymilacja danych (ABC i 3D-Var)


- **Cel:** Odtworzenie parametrów modelu i stanu układu na podstawie zaszumionych obserwacji w oknie czasowym.
- **Metody:**
 - **ABC (Approximate Bayesian Computation):** Metoda bezgradientowa, polegająca na losowaniu parametrów i akceptacji tych, które generują wyniki bliskie obserwacjom. Odporna na lokalne minima, ale kosztowna obliczeniowo.
 - **3D-Var (Variational):** Minimalizacja funkcji kosztu $J(x) = ||y - H(x)||^2$. Szybka zbieżność przy dostępnych gradientach, ale ryzyko utknięcia w minimach lokalnych.
- **Eksperyment:** Dane "rzeczywiste" z modelu PDE + szum Gaussowski. Testy dla modelu surogatowego ODE i pełnego PDE przy trzech budżetach czasowych (Low: 2s, Medium: 5s, High: 15s).

- **3D-Var:** Bardzo szybka zbieżność (czas $< 0.1s$). Błąd RMSE minimalny (≈ 0.006). Metoda idealna dla prostego modelu ODE.
- **ABC:** Wymaga wielu iteracji (tysiące). Błąd stabilny (≈ 0.012), ale wyższy niż w 3D-Var.
- **Wnioski:** Dla tanich modeli numerycznych metody gradientowe (lub quasi-newtonowskie) są bezkonkurencyjne.



Rysunek 3: Wyniki asymilacji ODE (Budżet High). Czerwona linia (Var) idealnie pokrywa się z prawdą.

- **Wyzwanie:** Wysoki koszt pojedynczej symulacji PDE drastycznie ogranicza liczbę iteracji.
- **ABC:** W budżecie 15s wykonano tylko ok. 76 iteracji. Mimo to, metoda znalazła przybliżone rozwiązanie ($\text{RMSE} \approx 0.026$).
- **3D-Var:** Metoda nie zdążyła wykonać skutecznej optymalizacji w zadanym czasie ($\text{RMSE} \approx 0.248$ - poziom zgadywania). Numeryczne wyznaczanie gradientu jest zbyt kosztowne dla PDE przy krótkim budżecie.



Rysunek 4: Wyniki asymilacji PDE (Budżet High). ABC (niebieska) radzi sobie lepiej niż przerwana optymalizacja wariacyjna.

Model	Metoda	Low (2s)	Medium (5s)	High (15s)
ODE	ABC	0.0127	0.0114	0.0117
ODE	3D-Var	0.0061	0.0061	0.0061
PDE	ABC	0.0247	0.0263	0.0263
PDE	3D-Var	0.2482	0.2482	0.2482

Tabela 1: Porównanie błędów RMSE predykcji dla całej trajektorii.


Wniosek: Do złożonych modeli (PDE) przy ograniczonym czasie, proste metody stochastyczne (ABC) mogą być bardziej "bezpieczne" niż kosztowne metody optymalizacyjne, chyba że dysponujemy analitycznym gradientem (Adjoint method).

Zadanie 6 — Model PINN (Physics-Informed Neural Network)


- **Idea:** Połączenie danych obserwacyjnych z wiedzą fizyczną zawartą w równaniach różniczkowych (PDE).
- **Architektura:** Sieć neuronowa $u_{NN}(x, t)$ aproksymująca rozwiązanie.
- **Funkcja kosztu:** $L = L_{data} + L_{physics}$
 - $L_{data} = \frac{1}{N_d} \sum (u_{NN}(x_i, t_i) - u_{obs})^2$ (dopasowanie do danych)
 - $L_{physics} = \frac{1}{N_f} \sum |f(u_{NN}(x_j, t_j))|^2$ (residuum PDE)
- **Zalety:** Możliwość trenowania na rzadkich danych i "uzupełniania" brakującej informacji fizyką.

Implementacja i Przebieg Treningu

- **Konfiguracja (utrudniona):** $n_x = 150$, $\Delta t = 5 \cdot 10^{-4}$, $N_{data} = 1200$, $N_f = 12000$, szum gaussian_mixture 5%.
- **Sieć:** MLP (5 warstw $\times$ 64, Tanh) z **residualnymi połączeniami**; **epoki:** 2000; **czas:** 76.58 s, CPU.
- **Techniki optymalizacji:** Learning rate scheduler (StepLR, $\gamma = 0.9$), gradient clipping, **warmup strategia dla weights fizyki** (λ_{phy} : 0.1 $\rightarrow$ 2.0 przez 500 epok).
- **Strata (ostatnia):** $L \approx 0.006$ (Data ≈ 0.0056 , Physics ≈ 0.00022) – znaczna poprawa stabilności i zbieżności.




Wyniki Rekonstrukcji Pola (PINN vs PDE)



Rysunek 6: Porównanie rozwiązania referencyjnego (PDE), predykcji PINN (ulepszonej) oraz błędu absolutnego. Błąd rozmieszczony równomiernie, niemal niewidoczny.

- **MAE:** 0.031193 (vs. 0.1855 baseline) — ****82.2% redukcja****
- **RMSE:** 0.058344 (vs. 0.2359) — ****75.3% redukcja****
- **reIL2:** 0.065468 (vs. 0.2647) — ****75.3% redukcja****
- Architektura residualna i warm-up strategia pozwalają na znacznie lepsze uczenie się fizyki mimo szumu.

Porównanie Dynamiki Średniej (PINN vs PDE vs ODE)




Rysunek 7: Porównanie średniej przestrzennej $u(t)$. PINN (ulepszona, czerwona przerywa) niemal idealnie pokrywa się z PDE (czarna ciągła).

- ****PINN (ulepszona)**** bardzo dokładnie śledzi prawdą trajektorię PDE
- Obie metody (PINN i ODE surrogate) wykazują zgodę w całym oknie czasowym
- Poprawa wynika z: (1) głębszej sieci, (2) residualnych połączeń, (3)

Zadanie 7 — Supermodel (ODE) i SuperNet (PINN)

- **Problem:** Modele często mają niedokładne parametry.
- **Rozwiązanie:** Połączenie wielu "niedoskonałych" modeli w jeden zespół (ensemble), który uczy się konsensusu.
- **Supermodel ODE:** Zespół modeli ODE sprzężonych członem relaksacyjnym (nudging) do średniej trajektorii.
- **SuperNet PINN:** Zespół sieci neuronowych uczonych równolegle z dodatkowym *Coupling Loss*, wymuszającym spójność predykcji w punktach kolokacji.




Rysunek 8: Supermodel ODE (czerwona) vs Prawda (czarna) vs Pojedyncze modele (zielone).

- Pojedyncze modele z zaburzonymi parametrami (p , q) znacznie odbiegają od prawdy.
- Sprzężony Supermodel redukuje błąd, choć z lekkim przewyższeniem w fazie nasycenia.

Wyniki: SuperNet PINN (Ulepszona)

- **Trening (ulepszone):** 3 sieci PINN, 2000 epok, czas: 186.24s (CPU), szum pomiarowy 5% + Coupling Loss.
- **Architektura:** Każda sieć: 5 warstw $\times$ 64 neurony z residualnymi połączeniami (jak w zad6)
- **Optymalizacja:** Learning rate scheduler, gradient clipping, ****warmup Coupling Loss**** (λ_{couple} : 0.1 $\rightarrow$ 0.5 przez 500 epok)
- **Strata (ostatnia):** Total ≈ 0.030 (znacznie lepiej niż poprzednio) — zbalansowana konwergencja.



Rysunek 9: Porównanie: SuperNet PINN (ulepszona, niebieska) vs Supermodel ODE (czerwona) vs Prawda (czarna).

Model	MAE	RMSE
Zadanie 6:		
Single PINN (baseline)	0.1855	0.2359
PINN (ulepszona)	0.0312	0.0583
Zadanie 7:		
Single Perturbed ODE	0.0549	0.1116
Supermodel ODE	0.0222	0.0451
SuperNet PINN (ulepszona)	0.0172	0.0178

Tabela 2: Zestawienie błędów rekonstrukcji średniej dynamiki — porównanie baseline vs. ulepszone modele.

Kluczowe ustalenia:

- ****Zad.6:**** Architektura residualna + warm-up fizyki dała 75-82% redukcję błędu PINN
- ****Zad.7:**** SuperNet PINN (z residualnym sprzęgiem i optymalizacją) ****przewyższa**** Supermodel ODE (MAE: 0.0172 vs 0.0222, RMSE: 0.0178 vs 0.0451)
- Głębokie sieci + residualny przepływ + adaptacyjne ważenie składników

- **PINN (Zad.6):** Przy poprawnej architekturze i strategii treningu, PINN może efektywnie łączyć dane zaszumione z wiedzą fizyczną, unikając przeuczenia.
- **SuperNet (Zad.7):** Ensemble podejście z PINN osiąga lepsze wyniki niż Supermodel ODE dzięki: (i) większej pojemności sieci, (ii) elastyczności w modelowaniu interakcji między zespołem, (iii) lepszemu przyswajaniu fizyki.
- **Wyzwania pozostające:** Interpretowalność sieci, kosztowne obliczenia pochodnych wyższych rzędów, konieczność tuningu hiperparametrów.
- **Rekomendacje:** Dla problemów z zaszumionymi danymi stosować (a) sieci głębokie z residualnymi połączeniami, (b) learning rate scheduling, (c) warmup dla wag fizyki, (d) ensemble modeli w celu zmniejszenia wariancji.