

A11 - Dyfuzja innowacji i popytu na rynku

Wojciech Bartoszek

Łukasz Checiak

Zadanie 1 - Wprowadzenie, SOTA i sformułowanie modelu

- **Dyfuzja innowacji** – proces upowszechniania się nowych produktów lub technologii w społeczeństwie, przechodzący kolejne fazy adopcji kolejnych grup odbiorców [?].
- Proces adopcji przebiega początkowo wolno, następnie nabiera tempa, często zgodnie z charakterystyczną krzywą S (funkcja logistyczna) [?].
- Wzrost popytu na innowację wspierają zarówno innowatorzy (early adopters), jak i mechanizm naśladownictwa („word-of-mouth”).
- Modele matematyczne umożliwiają kwantyfikację dynamiki popytu i adopcji (prognozowanie rozmiaru rynku) [?].

- **Model Bassa** (1969) – równanie różniczkowe opisujące tempo adopcji nowego produktu. Zakłada dwie kategorie nabywców: *innowatorów* (efekt zewnętrzny) i *naśladowców* (efekt imitacji). Równanie:
$$\frac{dF}{dt} = p(1 - F) + qF(1 - F),$$
 gdzie $F(t)$ to skumulowany udział adopcji, p – współczynnik innowacji, q – współczynnik imitacji [?]. Rozwiązanie daje S-kształtną krzywą adopcji: początkowo szybki wzrost, potem nasycenie.
- **Równanie Fishera–Kolmogorowa–Petrowskiego–Piskunowa (F-KPP)** – reakcyjno-dyfuzyjne równanie PDE: $u_t = D\Delta u + r u(1 - u)$ [?].
Proponowane w genetyce populacji (Fisher 1937) do opisanie fali rozprzestrzeniania korzystnego genu. W ekonomii modeluje propagację innowacji jako falę nasycenia (przejście od stanu bez adopcji do pełnej adopcji).
- **Przebieg krzywej adopcji** – obydwa powyższe modele generują krzywą typu logistycznego (S-kształtną): szybka faza początkowa (wzrost adopcji) i faza wygaszania przy nasyceniu rynku [?, ?].

Uogólnienie do modeli przestrzenno-czasowych (PDE)

- Dodanie wymiaru przestrzennego do modelu Bassa prowadzi do *równania cząstkowego różniczkowego*:

$$\frac{\partial F(x, t)}{\partial t} = D\Delta F + p(1 - F) + q F(1 - F),$$

gdzie D to współczynnik dyfuzji (intensywność rozprzestrzeniania informacji w przestrzeni) [?].

- Takie modele reakcji–dyfuzji uwzględniają mechanizmy lokalnej interakcji (zależność od odległości przestrzennej) oraz pierwiastek losowy/adopcyjny w zachowaniach konsumentów.
- Rozwiązania przyjmują formę propagujących się fal innowacji (autowal). Ich prędkość opisuje tempo rozwoju popytu w przestrzeni – np. Dubinina (2023) analitycznie wyprowadza falę podróżującą, określając czas osiągnięcia danego poziomu technologii [?].
- W praktyce modele PDE pozwalają analizować klastrowe rozprzestrzenianie się innowacji (np. koncentrujące się „fale adopcji” wokół centrów innowacyjności) oraz prognozować przestrzenne rozkłady popytu.

- Rozważmy zmienną $u(x, t) \in [0, 1]$ – skumulowany udział rynku opanowany przez innowację w punkcie x i czasie t . Proponowany model:

$$\frac{\partial u}{\partial t} = D \Delta u + (p + q u)(1 - u).$$

- Interpretacja parametrów: p – stopa innowacji (zewnętrzna, np. reklama), q – współczynnik imitacji (wewnętrzny, efekt „liczenia się z innymi”), D – współczynnik dyfuzji (szybkość propagacji informacji w przestrzeni).
- Warunki początkowe i brzegowe: np. $u(x, 0) = u_0(x)$ z niewielką liczbą pionierów w centrum, warunki Neumanna ($\nabla u \cdot n = 0$) na granicach.
- Model przewiduje przyspieszony wzrost adopcji w początkowej fazie i asymptotyczne nasycenie rynku ($u \rightarrow 1$). Rozwiązania (np. numeryczne lub w przybliżeniu falowe) pozwalają wyznaczyć czas rozprzestrzeniania innowacji i tempo wzrostu popytu [?].

- Modele przestrzenno-czasowe umożliwiają uwzględnienie efektów geograficznych: jak bliskość i sieci społeczne przyspieszają dyfuzję innowacji [?].
- Zastosowania: prognozowanie rozkładu adopcji w regionach, identyfikacja klastrów innowacji, planowanie strategii marketingowych z uwzględnieniem lokalizacji (marketing geograficzny).
- Kalibracja na danych empirycznych (np. historia adopcji technologii mobilnej) umożliwia przewidywanie tempa wzrostu popytu i oceny opóźnień geograficznych (patrz Dubinina 2023) [?].
- Dalszy rozwój modeli może uwzględniać heterogeniczność populacji, zależność od cen czy czynniki sieciowe, co można wprowadzić jako dodatkowe składniki PDE (np. sprzężenia zwrotne, nieliniowe czynniki) [?].

Zadanie 2 - Porównanie solverów dla modelu przestrzenno-czasowego

- Rozważamy model reakcyjno-dyfuzyjny dla udziału adopcji $u(x, t) \in [0, 1]$:

$$\frac{\partial u}{\partial t} = D \frac{\partial^2 u}{\partial x^2} + (p + q u)(1 - u).$$

- Parametry: D (dyfuzja), p (innowacja), q (imitacja). Warunki Neumanna na brzegach oraz lokalne warunki początkowe (pionierzy w centrum).
- Celem: porównać wydajność i stabilność rozwiązań dla różnych solverów oraz zidentyfikować bezpieczne przedziały parametrów.


- explicit: jawny Euler w czasie + centralna druga różnica w przestrzeni (najtańszy krok, ograniczony warunkiem CFL).
- semi-implicit: dyfuzja implicit (rozwiązanie układu liniowego), reakcja jawnie.
- crank-nicolson (CN): CN dla dyfuzji (2. rząd dokładności), reakcja jawnie; większy koszt na krok.

- Siatki w przestrzeni: $n_x \in \{50, 100, 200\}$.
- Kroki czasowe testowane: $\Delta t \in \{5 \cdot 10^{-5}, 10^{-4}\}$, całkowity czas symulacji: $T = 0.05$ (szybkie testy).
- Zestaw parametrów (D,p,q): (0.01,0.01,1.0), (0.1,0.001,5.0), (1.0,0.1,10.0).
- Mierzone metryki: czas wykonania (s), wykresy profilu $u(x)$, kontrola czy $u \in [0, 1]$ i czy występują NaN/Inf.


Wyniki z przebiegu eksperymentu (nagłówek: średni czas wyk. dla wszystkich kombinacji testowych):

- explicit — średni czas: ≈ 0.0048 s (min ≈ 0.0029 s, max ≈ 0.0068 s)
- semi-implicit — średni czas: ≈ 0.0329 s (min ≈ 0.0164 s, max ≈ 0.0568 s)
- crank-nicolson — średni czas: ≈ 0.0350 s (min ≈ 0.0178 s, max ≈ 0.0596 s)


Przykładowe profile rozwiązania



(a) explicit, $nx=100$



(b) semi-implicit, $nx=100$



(c) Crank-Nicolson, $nx=100$

- (1) Czas obliczeń: dla krótkich testów jawny solver był najszybszy ze względu na niski koszt pojedynczego kroku; schematy rozwiązujące układy liniowe były wolniejsze.
- (2) Stabilność: jawny (explicit) solver wymaga mniejszego kroku czasowego Δt przy wzroście D ($CFL \sim dx^2/D$); schematy semi-implicit i CN są bardziej odporne, ale droższe.
- (3) Parametry p, q : większe q przyspieszają nasycenie i mogą prowadzić do szybkich wzrostów lokalnych; zalecamy testy kalibracyjne na danych empirycznych.
- (4) Zakresy parametryczne (przykładowo): dla stabilnych symulacji przy $n_x = 100$ i $dt = 10^{-4}$ przykładowe granice to: $D \lesssim 0.1$ (dla explicit), $p \in [10^{-4}, 0.1]$, $q \in [0.1, 10]$ — jednak ostateczne granice wymagają szczegółowego testu stabilności i dokładności.

Zadanie 3 — Model surogatowy ODE dla dyfuzji innowacji

- **Cel:** Uproszczenie modelu PDE do modelu ODE poprzez eliminację zmiennej przestrzennej. Pozwala to na znacznie szybsze symulacje.
- **Metoda:** Uśrednienie równania PDE po całej dziedzinie przestrzennej $x \in [0, 1]$.


$$\frac{d}{dt} \int_0^1 u(x, t) dx = \int_0^1 Du_{xx} dx + \int_0^1 (p + qu)(1 - u) dx$$

- Przy warunkach brzegowych Neumanna, człon dyfuzyjny się zeruje:
 $\int_0^1 Du_{xx} dx = D[u_x]_0^1 = 0$.
- Definiując $U(t) = \mathbb{E}[u(x, t)] = \int_0^1 u(x, t) dx$ i stosując przybliżenie $\mathbb{E}[R(u)] \approx R(\mathbb{E}[u])$, otrzymujemy model surogatowy ODE:

$$\frac{dU}{dt} = (p + qU)(1 - U)$$

- Używamy prostej sieci neuronowej (MLP) do nauczenia się dynamiki średniej wartości $U(t)$ bezpośrednio z danych.
- **Dane uczące:** Szereg czasowy średniej wartości z symulacji PDE, $\{(t_i, U_{PDE}(t_i))\}$.
- **Architektura:** Sieć z jedną warstwą wejściową (czas), dwiema warstwami ukrytymi (z funkcją aktywacji ReLU) i jedną warstwą wyjściową (przewidywana wartość $U(t)$).
- **Cel:** Sprawdzenie, czy model oparty na danych może być dokładniejszy niż uproszczony model analityczny ODE.

Porównanie wszystkich trzech modeli



Rysunek 2: Porównanie średniej z modelu PDE, modelu surogatowego ODE oraz predykcji sieci neuronowej.

- Czas inferencji dla modelu ODE: 0.0011657 s
- Czas inferencji dla prostego modelu NN: 0.0006749 s

- Modele surogatowe (zarówno analityczne ODE, jak i sieci neuronowe) są potężnym narzędziem do przyspieszania symulacji złożonych systemów PDE.
- Model ODE, mimo swojej prostoty, dostarcza dobrego przybliżenia ogólnej dynamiki systemu.
- Sieci neuronowe mogą osiągnąć wyższą dokładność, ale wymagają danych treningowych i nie dostarczają analitycznego wglądu w mechanizmy systemu.
- Wybór odpowiedniego modelu surogatowego zależy od wymagań dotyczących dokładności, dostępności danych i potrzeby interpretowalności wyników.