


A11 — Dyfuzja innowacji i popytu na rynku

Wojciech Bartoszek Łukasz Checiak

- Model: $u_t = D\Delta u + (p + qu)(1 - u)$ — łączenie Bassa i F-KPP.
- Interpretacja: p = innowacja (zew.), q = imitacja (wewn.), D = dyfuzja (przestrz.).
- Kluczowy insight: krzywa adopcji typu S; przestrzenne modele dają propagujące się fale.

Zadanie 2 — Porównanie solverów


- Testowane solvery: explicit, semi-implicit, Crank–Nicolson.
- Czas (średnio): explicit 0.0048 s; semi-implicit 0.0329 s; CN 0.0350 s.
- Wniosek: explicit najszybszy dla małych testów, ale wymaga małych Δt (CFL).



Przykładowy profil $u(x)$ (explicit)


Zadanie 3 — Surogat ODE i NN

- Uśrednienie PDE dało ODE: $\dot{U} = (p + qU)(1 - U)$ — szybkie przybliżenie średniej.
- NN (MLP) jako surogat: wejście $(t, D, p, q) \mapsto U(t)$ — natychmiastowa predykcja.
- Czas inferencji: ODE 1.29 ms, NN 0.87 ms; dobry kompromis dokładność/prędkość.




Zadanie 4 — Analiza wrażliwości

- Metody: Morris (screening) i Sobol (wariancja globalna).
- Wynik: parametr q (imitacja) ma dominujący wpływ (wysokie μ^* i S_T); p umiarkowane, D mały wpływ na średnią.




Zadanie 5 — Asymilacja danych

- Cel: Estymacja parametrów + stanu na podstawie zaszumionych obserwacji.
- ODE: 3D-Var szybki i najlepszy (RMSE 0.0061). ABC wolniejszy, RMSE 0.0117.
- PDE: ABC radzi sobie lepiej (RMSE 0.026) niż przerwana 3D-Var (RMSE 0.248) przy limitowanym budżecie.



Zadanie 6 — PINN

- PINN: trenowana z $\text{loss} = \text{data} + \text{physics}$; techniki: residuals, warm-up λ_{phy} , schedulery.
- Wynik (ulepszone): MAE 0.0312, RMSE 0.0583 — znacząca redukcja błędów względem baseline.



Zadanie 7 — Supermodel i SuperNet

- Supermodel ODE (ensemble + nudging) redukuje błąd (RMSE: 0.0451 vs single 0.1116).
- SuperNet PINN (ensemble PINN + coupling) osiąga najlepsze wyniki: MAE 0.0172, RMSE 0.0178.

